


Detekcija klikbejta u srpskim sportskim naslovima

Vodič kroz projekat — objašnjeno od nule, uz slike



Obrada prirodnih jezika 2025/2026 — ETF

Filip Nikolić (25/3234) · Danilo Nikolić (25/3235)

Ovaj dokument objašnjava *šta* smo radili, *kako* to radi i *zašto* baš tako — pretpostavljajući da o oblasti ne znate ništa unapred.

Sadržaj

1. Šta uopšte pravimo? (problem na jednom primeru)
2. Ceo tok projekta u 4 koraka
3. Faza 1 — odakle podaci
4. Faza 2 — kako smo „naučili“ računar šta je klikbejt
5. Kako mašina uopšte uči (osnovni pojmovi)
6. Kako merimo da li je model dobar
7. Faza 3a — jednostavni modeli (vreća reči)
8. Faza 3b — neuronska mreža (BERT): srce projekta
9. Faza 3c — veliki jezički model (Claude) bez obuke
10. Rezultati i zaključak

1 · Šta uopšte pravimo?

Pravimo program koji pročita **naslov sportske vesti** i kaže da li je to „**klikbejt**” (naslov koji vas vara da kliknete) ili „**regularan**” naslov (pošteno vam kaže šta se desilo).

Klikbejt (od engleskog *click* = klik, *bait* = mamac) je naslov napravljen tako da vas **natera na klik**, a ne da vas informiše. Tipičan trik: sakrije ključnu informaciju da biste morali da otvorite članak. Naš zadatak je da to automatski prepoznamo. U informatici se ovakav zadatak zove **klasifikacija teksta** — svrstavanje teksta u jednu od unapred poznatih grupa (ovde: dve grupe, „klikbejt” i „regularan”).

✗ KLIKBEJT (1)
„Nećete verovati šta je kapiten uradio posle meča!”

✓ REGULARAN (0)
„Partizan pobedio Zvezdu 2:1 u 165. derbiju”

4 mehanizma manipulacije (dovoljan je 1 za oznaku „klikbejt”):

Kognitivni jaz
krije ključnu informaciju

Preuveličavanje
rutina = senzacija

Emocionalni naboj
veštačka napetost


Senzac. fraza
„a onda se desilo...”

Primer: levo klikbejt (krije ko/šta), desno regularan naslov. Klikbejt prepoznamo po 4 mehanizma manipulacije.

Zašto je ovo teško? Klikbejt nije samo uzvičnik ili velika slova. Često je suptilan — ista rečenica može biti i poštena i manipulativna, zavisno od toga *šta krije*. Zato program mora da razume **smisao**, ne samo da prebroji reči.

2 · Ceo tok projekta u 4 koraka

Svaki ovakav projekat ide istim redom: prvo skupiš podatke, pa ih ručno označiš, pa naučiš program da pogađa, pa sve to opišeš. To su naše četiri faze:



Četiri faze: prikupljanje → ručno označavanje → modeli (obuka i provera) → dokumentacija.

- **Faza 1 – Prikupljanje:** skupili smo skoro 3000 naslova sa sajta SportKlub.
- **Faza 2 – Anotacija:** ručno smo svakom naslovu dodelili oznaku 1 (klikbejt) ili 0 (regularan).
- **Faza 3 – Modeli:** naučili smo tri vrste programa da pogađaju oznaku i izmerili ko je najbolji.
- **Faza 4 – Dokumentacija:** napisali izveštaj sa rezultatima (ovaj dokument je deo toga).


3 · Faza 1 — odakle podaci

Da bi program nešto naučio, mora da vidi **mnogo primera**. Skupili smo **2994 različita naslova** sa portala **SportKlub** (automatski, preko njihovog veb interfejsa), uklonili duplikate i za svaki zapisali odakle je (link, rubrika, datum).

Zašto samo jedan sajt? Da program uči razliku *klikbejt vs regularno*, a ne razliku *SportKlub vs neki drugi portal*. Kad su svi naslovi sa istog mesta, jedina razlika koju može da nauči je upravo ona koja nas zanima.

4 · Faza 2 — kako smo „naučili" računar šta je klikbejt

Računar ne zna unapred šta je klikbejt. Mi mu to pokazujemo tako što **sami** označimo hiljade naslova. Ali da bismo bili sigurni da je naša definicija jasna, prvo smo uradili **kalibraciju**: oba člana tima su **nezavisno** (svako za sebe, bez dogovaranja) ocenila istih 220 naslova. Pa smo uporedili koliko se slažemo.




Kalibracija: dva čoveka nezavisno ocene iste naslove, pa merimo slaganje. Visoko slaganje = definicija je jasna.

Slagali smo se u **82.7%** slučajeva. Ali postoji bolji način merenja od pukog procenta — **Cohen-ova kapa (κ)**. Ona je stroža jer oduzima slaganje koje bi se desilo i čistim nagađanjem. Dobili smo **κ = 0.64**, što spada u „dobro" slaganje (cilj je bio ≥ 0.6).

Šta nam to govori? Naša neslaganja bila su na *suptilnim*, graničnim naslovima — ne na očiglednim. To znači da zadatak nije trivijalan i da je naša definicija dovoljno dobra da se na nju oslonimo.

Nakon kalibracije, podelili smo ostatak posla na pola i označili sve. Konačni skup za treniranje je **balansiran: 1100 klikbejt + 1100 regularnih = 2200 naslova**.




Konačni skup je namerno 50:50. Balans je važan da program ne bi „švercovao“ tako što uvek pogađa češću klasu.

Zašto baš 50:50? Ako bi 95% naslova bilo regularno, program koji uvek kaže „regularno“ imao bi 95% tačnost — a zapravo ništa ne bi naučio. Balansiran skup sprečava ovu varku i čini merenje uspeha poštenim.

5 · Kako mašina uopšte uči (osnovni pojmovi)

Pre nego što opišemo modele, evo tri pojma koja sve objašnjavaju. Zamislite učenika koji se sprema za ispit iz zbirke zadataka.

Premalo vs taman vs previše učenja



Tačkice su podaci, linija je ono što je model naučio. Levo: presimplifikovano. Sredina: taman. Desno: model je „nabubao” i šum.

- **Premalo (underfitting):** učenik je naučio premalo pravila — greši čak i na poznatom.
- **Taman:** uhvatio je pravo pravilo — dobro radi i na novim zadacima.
- **Previše (overfitting):** učenik je *napamet nabubao* baš te zadatke, uključujući i slučajne detalje — na novom zadatku se izgubi. Ovo je glavna opasnost.

Zašto se ne sme proveravati na istim zadacima na kojima se učilo

Ako učenika ispitate baš iz zadataka koje je vežbao, dobićete lažno visoku ocenu. Zato uspeh merimo na **novim** naslovima koje model nije video tokom učenja.

Unakrsna validacija — pošteno merenje sa malo podataka

Imamo „samo” 2200 naslova. Da iskoristimo svaki, koristimo **10-struku unakrsnu validaciju**: podelimo podatke na 10 delova; u 10 prolaza svaki put 9 delova služi za učenje, a 1 (uvek drugi) za proveru. Konačna ocena je prosek svih 10 prolaza.

10-struka unakrsna validacija (ovde prikazano 5 radi jasnoće)

prolaz 1	TEST	obuka	obuka	obuka	obuka
prolaz 2	obuka	TEST	obuka	obuka	obuka
prolaz 3	obuka	obuka	TEST	obuka	obuka
prolaz 4	obuka	obuka	obuka	TEST	obuka
prolaz 5	obuka	obuka	obuka	obuka	TEST


Svaki deo jednom bude TEST. Rezultat = prosek svih prolaza → pouzdanija ocena, koristi sve podatke.

Svaki deo jednom postane „test“. Tako je svaki naslov bar jednom proveren, a ocena je stabilnija.

Ugnežđena validacija — da izbor podešavanja ne „vara“

Modeli imaju „dugmiće“ (npr. jačina regularizacije) koje treba podesiti. Ako bismo ih podešavali gledajući isti test, varali bismo. Zato se podešavanje radi u **unutrašnjoj** petlji, odvojeno od konačne provere u **spoljnoj** petlji.


Ugnežđena (nested) CV — pošten izbor hiperparametara



Test deo nikad ne učestvuje u biranju podešavanja → poštena, neiskvarena ocena.

6 · Kako merimo da li je model dobar

Kad model pogađa, postoje četiri ishoda. Skupljamo ih u **matricu zabune**:



Pogodci i greške. „Pozitivna“ klasa nam je klikbejt — to je ono što želimo da uhvatimo.

- **Preciznost:** kad model kaže „klikbejt“, koliko često je u pravu? (malo lažnih uzbuna)
- **Odziv (recall):** od svih pravih klikbejtova, koliko ih je uhvatio? (malo promašenih)
- **F1:** jedan broj koji balansira preciznost i odziv — naša glavna ocena.
- **ROC-AUC:** meri koliko dobro model *rangira* klikbejt iznad regularnog; pokazuje kvalitet „sigurnosti“ modela, ne samo konačnu odluku.


Sve modele merimo **istim metrikama** i **istim postupkom** — samo tako je poređenje pošteno.

7 · Faza 3a — jednostavni modeli („vreća reči“)

Prvo pravimo **najjednostavnije moguće** modele kao **donju lestvicu** (baseline). Bez njih ne bismo znali da li je složeni model stvarno dobar ili samo deluje tako.

Korak 1: pretvoriti reči u brojeve


Računar ne razume slova — razume brojeve. Najjednostavniji način: **vreća reči**. Naslov pretvorimo u listu reči, a zatim u vektor koji broji koja se reč javlja. Redosled reči se **ignoriše** — otud „vreća“.



Naslov → reči → vektor brojeva. Ovo je ulaz za jednostavne modele.

Korak 2: nisu sve reči podjednako važne (TF-IDF)

Reč „je“ se javlja svuda i ne govori ništa; retka, karakteristična reč govori mnogo. **TF-IDF** daje veću težinu retkim, informativnim rečima.



TF-IDF = koliko je reč česta u naslovu × koliko je retka u celom skupu.

Modeli koje smo probali


Dva klasična: **logistička regresija** (uči težinu svake reči) i **naivni Bajes** (računa verovatnoće na osnovu toga koje se reči javljaju u kojoj klasi). Najbolji rezultat dao je naivni Bajes.

Iskren nalaz: ovi modeli gledaju reči *izolovano*, pa hvataju samo površinske obrasce. Klikbejt koji zavisi od konstrukcije rečenice im izmiče. Najbolji baseline ima **F1 = 0.646** — to je lestvica koju složeniji modeli treba da preskoče.

8 · Faza 3b — neuronska mreža (BERT): srce projekta

Ovo je najvažniji deo. Umesto da gleda reči izolovano, ovaj model čita **ceo naslov u kontekstu** — razume da „Nećete verovati šta...” jeste manipulacija, bez obzira na pojedinačne reči.


Dve vrste „velikih jezičkih modela"



Enkoder (BERT) razume tekst i može se dotrenirati kod nas. Dekoder (Claude) generiše tekst i samo ga pitamo.

Šta je BERT i kako „misli"


BERT je neuronska mreža (mreža sloj-na-sloj povezanih „neurona“) posebno napravljena za jezik. Naslov prolazi kroz nekoliko koraka:



Put naslova kroz BERT: tokenizacija → vektori → slojevi pažnje (kontekst) → [CLS] sažetak → odluka.

- **Tokenizacija:** tekst se iseče na delove reči (npr. „pojačanje“ → „poja-“ + „##čanje“). Dodaju se posebne oznake [CLS] (početak) i [SEP] (kraj).
- **Vektori (embedding):** svaki delić dobije svoj niz brojeva + informaciju o poziciji.

- **Self-attention (pažnja):** srce mreže — svaka reč „pogleda“ sve ostale i pokupi kontekst od njih. Tako značenje reči zavisi od okoline.
- **Odluka:** poseban [CLS] vektor sažme ceo naslov i mali završni sloj kaže 1 ili 0.



Mehanizam pažnje: reč „verovati“ pokuplja jak signal od „Nećete“ i „uradio“ → prepoznaje manipulativnu frazu.

Trik: ne učimo jezik od nule (transferno učenje)

Naučiti mrežu „šta je srpski“ zahteva milijarde rečenica i ogromne računare. Zato uzimamo mrežu koju je **neko već unapred istrenirao** na ogromnom tekstu, pa je samo **blago doteramo** na našim 2200 naslova. To se zove **fine-tuning**.




Pretrening (tuđi, skup) + fino doterivanje (naš, jeftin) = gotov klasifikator. Zato je dovoljno malo primera.

Dva modela koja smo poredili

- **BERTić** — istreniran **baš za srpski** (i srodne jezike).
- **mBERT** — „višejezični“, zna 104 jezika odjednom, pa nijedan savršeno.

Probali smo i različit broj „prolaza kroz podatke“ (epoha): 2, 3 i 4.




Sa 2 epohe model je nedovoljno istreniran; 3–4 epohe daju najbolji rezultat. Dalje nema dobitka.

Model	Epohe	F1 (klikbejt)	Tačnost	ROC-AUC
BERTić	2	0.681	0.680	0.760
BERTić	3–4	0.703	0.704	0.788
mBERT	2	0.651	0.664	0.736
mBERT	3	0.690	0.687	0.753

Zaključak faze: BERTić > mBERT (namenski srpski model je bolji), a **oba ubedljivo nadmašuju baseline**. To je glavni dokaz projekta: razumevanje konteksta hvata suptilni klikbejt koji „vreća reči" ne može.

9 · Faza 3c — veliki jezički model (Claude) bez obuke

Modeli tipa **ChatGPT / Claude** su ogromni i zatvoreni — ne možemo ih dotrenirati. Ali možemo ih jednostavno **pitati**. To zovemo **zero-shot**: damo uputstvo i naslov, i tražimo odgovor 1 ili 0 — **bez ijednog primera za obuku**.



Damo modelu uputstvo (prompt) i naslov; on vrati 1 ili 0. Nema treniranja — samo pitanje i odgovor.

Postavka traži da uporedimo **jezik uputstva**: srpski vs engleski prompt. Važno: **naslovi su uvek srpski** — menja se samo jezik instrukcije modelu.


Varijanta upita	F1 (klikbejt)	Tačnost	Preciznost	Odziv
Srpski prompt	0.710	0.695	0.676	0.748
Engleski prompt	0.715	0.691	0.664	0.775

Nalaz: srpski i engleski prompt daju gotovo isti rezultat. Model bez ijednog primera za obuku postiže **najviši F1 u celom projektu (0.715)** — impresivno.


Koristili smo **Claude** (jeftin, ~\$1 za ceo skup) jer besplatni Gemini nije bio dostupan, a postavka izričito dozvoljava „i druge“ generativne modele.

10 · Rezultati i zaključak

Konačno poređenje svih pristupa po glavnoj metrici (F1 na klikbejt klasi):



Svi modeli su iznad baseline-a. Kontekstualni modeli (BERTić, Claude) jasno vode.



Isti zaključak, prikaz iz zvaničnog izveštaja.

Model	Tip	F1 (kb)	Tačnost	ROC-AUC
Naivni Bajes	baseline (vreća reči)	0.646	0.622	0.676
mBERT	neuronska mreža (višejezična)	0.690	0.687	0.753
BERTić	neuronska mreža (srpska)	0.703	0.704	0.788
Claude (EN)	generativni, bez obuke	0.715	0.691	—

Šta smo naučili

- Svi modeli su bolji od baseline-a — razumevanje konteksta pobeđuje brojanje reči.

- **Claude** ima najviši F1 iako nije ni treniran — snaga ogromnih jezičkih modela.
- **BERTić** je najbolji po tačnosti i jedini daje pouzdane „verovatnoće“ (ROC-AUC), a uz to je mali, besplatan i radi lokalno.
- Za srpski je **namenski model bolji** od višejezičnog.

Preporuka: za stvarnu upotrebu → **BERTić** (besplatan, lokalan, pouzdan). Kada nema podataka za obuku → **Claude** u zero-shot režimu. Jednostavni modeli ostaju korisni kao brza, providna referenca.

Kraj vodiča. Za tehničke detalje i komande videti **[docs/Sve-o-projektu.md](#)** i **[docs/Radni-izvestaj.md](#)**.