

Obrada prirodnih jezika

Projekat za školsku 2025/2026. godinu

Tema projekta

U školskoj 2025/2026 godini tema predmetnog projekta je izrada rešenja za odabrani zadatak u obradi tekstova na srpskom jeziku. Dozvoljen je slobodan izbor zadatka u obradi prirodnih jezika za koji će izrada projekta biti vezana. To može biti neki od popularnih/čestih zadataka na nivou morfologije, (morfo)sintakse ili semantike koji su razmatrani u okviru predavanja, ali je dozvoljen i odabir novijih zadataka (ili varijanti zadataka) koje su tek nedavno formulisane, poput onih koje se javljaju u okviru *SemEval* konferencija.

Projekti će se izrađivati grupno. Proces prijavljivanja grupe je opisan u odeljku o propozicijama izrade projekta. Projekat se može implementirati u programskom jeziku i paketu po izboru. Moguće je i da više grupa razmatra jedan isti zadatak, ali sa fokusom na različite tematske domene tekstova (npr. novinski, pravni, književni, itd.).

Izrada projekta podrazumeva prikupljanje odgovarajućeg skupa polaznih tekstova na srpskom jeziku iz odabranog domena, kao i ručnu anotaciju prikupljenih podataka na način koji je primeren odabranom NLP zadatku. Tako kreirani skup podataka je zatim potrebno iskoristiti za obučavanje i evaluaciju nekoliko različitih statističkih modela.

Projekat može da razmatra i zadatak za koji su već razvijena neka rešenja na srpskom jeziku, ali tada fokus projekta mora biti na nekom novom tematskom domenu tekstova. U tom slučaju, dozvoljeno je da se u fazama prikupljanja i/ili anotacije podataka isprati ranije predstavljen standardizovan sistem prikupljanja i/ili anotacije podataka, ali je zato u fazi obučavanja i evaluacije modela dodatno potrebno razmotriti efekte promene domena na ponašanje modela. Drugim rečima, u ovakvim situacijama rešenja obučena na/prilagođena ranijem domenu tekstova je potrebno evaluirati na podacima iz novog domena tekstova, i obrnuto. Pri tome, očekuje se da evaluacija sadrži analizu povezanosti posmatranih domena tekstova i efekata te povezanosti na ponašanje modela.

Neophodno je učešće svih članova grupe u svim fazama izrade projekta, tj. nije dozvoljena podela posla između članova grupe po fazama. U nastavku će biti detaljnije opisana svaka od faza.

Faza 1 - Prikupljanje podataka

Proces prikupljanja podataka podrazumeva formiranje dovoljno velikog skupa tekstova za odabrani tematski domen, tako da se takav skup može nakon anotacije iskoristiti za obučavanje i evaluaciju statističkih modela. Stoga pri izboru tematskog domena treba najpre razmotriti za koji domen je moguće pronaći dovoljne količine tekstova na srpskom za odabrani problem. Kao izvor podataka za formiranje ovakvog skupa tekstova mogu poslužiti bilo koji javno dostupni veb sajtovi sa sadržajem na srpskom jeziku.

Formirani skup treba da sadrži minimalan broj tekstova koji će biti određen konkretnim zadatkom koji se razmatra i veličinom grupe. Pošto između zadataka mogu postojati velike razlike u formatu podataka i tipu anotacije, konkretan minimalan broj tekstova će u dogovoru sa predavačem biti utvrđen za svaku grupu zasebno, nakon što grupa ispita dostupnost adekvatnih podataka na internetu. Pri tome, dozvoljeno je da se u tekstovima pisanim na srpskom jeziku javi i poneki termin napisan na engleskom, pri čemu je za očekivati da će ovo u nekim tematskim domenima (npr. onim vezanim za tehničke uređaje) biti frekventnija pojava nego u drugim. Finalni skup prikupljenih tekstova treba pročistiti od dupliranih unosa istog teksta.

Prikupljeni tekstovi treba da budu sačuvani u vidu UTF-8 enkodovanih TXT fajlova, u formatu koji je pogodan za zadatak koji se razmatra. Očekuje se da se u metapodacima za prikupljene tekstove zabeleži i URL ili jedinstveni identifikator izvora iz koga je svaki tekst dobijen.

Faza 2 – Anotacija podataka

U ovoj fazi potrebno je svaki od prikupljenih tekstova ručno obeležiti shodno NLP zadatku koji se razmatra, korišćenjem adekvatne šeme oznaka/ocena za posmatrani zadatak. U odabiru/formiranju šeme oznaka, dozvoljeno je konsultovanje relevantnih naučnih radova, ali se takođe očekuje i uvid u konkretne prikupljene podatke, da bi se osigurala potpunost.

Za sprovođenje anotacije dozvoljeno je, ali ne i neophodno, koristiti bilo koji namenski program za anotaciju, bilo neki postojeći, bilo neki razvijen od strane grupe. U sprovođenju anotacije treba pratiti standardnu metodologiju označavanja podataka, koja podrazumeva:

1. Odabir oznaka
2. Formulisanje uputstava za anotaciju – ova uputstva bi trebalo da sadrže jasne definicije za svaku od oznaka koje se koriste u anotaciji, kao i usaglašene instrukcije za sistematsko postupanje u karakterističnim problematičnim situacijama.
3. Kalibraciju – proveru upotrebljivosti kreiranog skupa oznaka i uputstava za anotaciju uz pomoć malog podskupa primera tekstova (oko 10% od ukupnog broja) koje svi članovi grupe treba da paralelno anotiraju, zasebno i bez međusobnih konsultacija. Ako se u ovom koraku uoče nedostaci u skupu oznaka ili u uputstvima, treba se vratiti na neki od prethodnih koraka.
4. Sprovođenje anotacije – podatke bi trebalo ravnomerno rasporediti između svih članova grupe, tako da svako anotira približno istu količinu podataka. Očekuje se da anotacija glavnog seta tekstova bude jednostruka, ali nije zabranjeno višestruko paralelno označavanje, ako članovi grupe procene da se time znatno podiže konzistentnost generisanih oznaka.
5. Analizu anotacije – određivanje saglasnosti anotatora na osnovu kalibracionog skupa (stepen saglasnosti između svaka dva člana grupe, kao i grupni prosek binarnih stepena saglasnosti), statističku analizu oznaka u finalnim podacima, itd.

Anotirane podatke treba sačuvati u vidu UTF-8 TXT fajlova, u formatu koji je standardan za zadatak koji se razmatra. Podatke iz skupa za kalibraciju treba sačuvati zasebno, sa onoliko anotacija koliko ima članova grupe, pri čemu za sve anotacije treba koristiti isti format zapisa.

Faza 3 - Obučavanje i evaluacija statističkih modela

U ovoj fazi potrebno je razmotriti dva tipa statističkih modela za rešavanje odabranog NLP zadatka:

1. Osnovni modeli – u ovaj tip modela spadaju jednostavni ili linearni modeli, koji predstavljaju baseline rešenja za posmatrani zadatak. Na primer, za zadatke klasifikacije teksta, tu bi spadali linearni klasifikatori sa ručno definisanim odlikama, poput logističke regresije ili metode potpornih vektora. Iste metode se mogu primeniti kao baseline i u zadacima koji podrazumevaju modeliranje sekvencijalnih podataka (npr. prepoznavanje imenovanih entiteta), tako što će se vršiti zasebne predikcije za svaki element sekvence/token. Ovakvi modeli se mogu lako obučavati i evaluirati na lokalnim CPU jedinicama standardnih računara. Izbor konkretnih osnovnih modela za odabrani zadatak treba da bude sproveden u konsultaciji sa predavačem. U zavisnosti od zadatka koji se razmatra i konkretnih osnovnih modela, može biti primereno da se razmotre efekti različitih tehnika pretprocesiranja teksta, poput normalizacije na mala slova (*lowercasing*), TF, IDF i TFIDF ponderisanja, itd.
2. Veliki jezički modeli zasnovani na neuralnim Transformer arhitekturama. Moguće je razmatranje jednog ili oba podtipa ovakvih modela (u zavisnosti od veličine grupe i kompleksnosti ostalih delova projekta za izabrani NLP zadatak):
 - a. Enkoderski veliki jezički modeli – u ovaj tip modela spada *BERT*¹, kao predstavnik monolingvalnih modela, i veći broj multilingvalnih modela, poput *multilingual BERT*, *XLM*, itd. Potrebno je razmotriti barem po jedan mono- i jedan multilingvalni model. Za rad sa ovakvim modelima preporučuje se korišćenje *Huggingface Transformers* biblioteke ili interfejsa *Simple Transformers*¹. Ove modele je neophodno fino podesiti (engl. *fine tuning*) za odabrani NLP zadatak i zatim ih evaluirati. Za efikasno obučavanje/fino podešavanje i evaluaciju ovakvih modela neophodno je koristiti GPU jedinice sa dovoljno video RAM-a (zavisno od odabranog modela, najčešće ≥ 8 GB). Preporučuje se da se za sprovođenje eksperimenata sa ovakvim modelima koristi servis Google Colab ili studentski krediti na MS Azure platformi.
 - b. Dekoderski/generativni veliki jezički modeli – najpoznatiji predstavnici ovog tipa modela jesu ChatGPT i Gemini, ali je dozvoljeno razmatranje i drugih sličnih modela. Njihova veličina/broj parametara i zatvorenost čine fino podešavanje nemogućim, te se oni ne mogu obučiti na kreiranom skupu podataka, već samo evaluirati. Zbog toga je neophodno razmotriti efekte različitih formata upita zadatih ovim sistemima (engl. *prompt engineering*), kao i efekte odabira jezika na kojem se upiti formulišu (engleski / srpski).

Konkretnan izbor svih modela koji će biti korišćeni zavisi od NLP zadatka koji se razmatra i treba ga formulisati u konsultaciji sa predavačem prilikom prijave predloga projekta. Obučavanje i evaluaciju osnovnih i enkoderskih velikih jezičkih modela potrebno je sprovesti putem 10-slojne stratifikovane unakrsne validacije, korišćenjem odgovarajuće metrike za merenje performansi. Pritom, glavne hiperparametre osnovnih modela (npr. za linearne klasifikatore hiperparametar koji određuje jačinu regularizacije) treba optimizovati korišćenjem ugneždene unakrsne validacije. S druge strane, kod enkoderskih velikih jezičkih modela treba sprovesti evaluaciju različitih varijanti modela u zavisnosti od broja epoha, tj. od dužine trajanja procesa finog podešavanja. Kod dekodskih/generativnih velikih jezičkih modela ceo skup podataka treba koristiti za evaluaciju modela.

¹ <https://github.com/ThilinaRajapakse/simpletransformers>

Zvaničan domen sa dokumentacijom ovog interfejsa je trenutno oboren, pa se preporučuje pristup preko Internet Archive: <https://web.archive.org/web/20260218084422/https://simpletransformers.ai/>

Propozicije izrade projekta

Optimalna veličina grupe je četvero studenata, ali su dozvoljene grupe i od troje ili petoro članova. Pre otpočinjanja rada na projektu, neophodno je formirati i zvanično prijaviti grupu putem mejla, na adresu: vuk.batanovic@etf.bg.ac.rs. Prilikom prijave grupe, neophodno je navesti spisak članova grupe, izbor NLP zadatka i tematskog domena tekstova koje bi grupa želela da razmatra, spisak izvora podataka koji bi se koristili za taj zadatak i domen, procenu veličine skupa podataka koji će biti izrađen, kao i spisak modela koje grupa planira da razmatra. Grupi će zatim u najkraćem roku biti zvanično dodeljen zadatak i tematski domen ako nije već zauzet od strane neke ranije prijavljene grupe.

Studenti se mogu sami organizovati u grupe. Za slučaj nemogućnosti samoorganizovanja u grupe, studenti mogu i da se individualno prijave za izradu projekta. U tom slučaju, biće od strane predavača organizovani u grupe sa ostalim studentima koji su se individualno prijavili ili će, u slučaju nedovoljnog broja tako prijavljenih studenata, biti pridruženi nekoj od već formiranih grupa. U drugom slučaju individualno prijavljeni studenti neće imati mogućnost izbora zadatka i tematskog domena tekstova koje razmatraju.

Ova postavka predmetnog projekta će važiti do prolećnog semestra naredne školske godine. Grupe je potrebno formirati i prijaviti najkasnije do 01.08.2026, bez obzira na konkretan ispitni rok u kome se planira odbrana. Individualne prijave treba dostaviti najkasnije do 01.07.2026. Ni grupne ni individualne prijave nakon tih datuma neće biti uzimane u obzir.

Grupe koje žele da brane projekat u određenom ispitnom roku treba da pošalju urađeno rešenje i projektnu dokumentaciju do početka istog ispitnog roka, na adresu: vuk.batanovic@etf.bg.ac.rs.

U projektnoj dokumentaciji treba detaljno opisati svaku od faza izrade projekta. Ovo podrazumeva temeljno opisivanje procesa prikupljanja podataka, izvora podataka, navođenje kriterijuma koji su u tom procesu korišćeni i opisivanje kako je proces obavljen sa tehničkog aspekta. Pored toga, dokumentacija mora sadržati detaljan opis anotacije podataka, uključujući uputstva za anotaciju, kao i opis tehničke strane označavanja podataka. Takođe se očekuje da izveštaj sadrži deskriptivni statistički prikaz prikupljenih i anotiranih podataka. Za fazu obučavanja i evaluacije statističkih modela podrazumeva se da izveštaj sadrži pregledni tabelarni prikaz rezultata različitih (varijanti) modela i efekata različitih podešavanja, kao i analizu i diskusiju dobijenih rezultata. Dokumentacija ne treba da sadrži iskopirana detaljna objašnjenja iz nastavnih materijala za korišćene tehnike i algoritme.

Ukoliko su projektna rešenja i dokumentacija adekvatni, u dogovoru sa studentima biće određen termin odbrane projekta u toku ispitnog roka. Odbrane će biti moguće u svim ispitnim rokovima predviđenim za predmete iz letnjeg semestra.

Ocene će se dobijati na osnovu broja prikupljenih bodova na skali 0-100, prema sledećoj raspodeli:

- 25 poena – faza prikupljanja podataka
- 25 poena – faza anotacije podataka
- 40 poena – faza obučavanja i evaluacije statističkih modela (20 poena za osnovne modele + 20 poena za velike jezičke modele)
- 15 poena – kvalitet i potpunost priložene projektne dokumentacije

Za svaku od prve tri stavke neophodno je da grupa ostvari barem polovinu od minimalnog broja poena. Drugim rečima, nije moguće odbraniti projekat bez sprovođenja i opisivanja sve tri faze izrade. Ukoliko se projekat odnosi na zadatak koji je u nekom tekstualnom domenu već razmatran za srpski jezik i ukoliko je projektna metodologija prikupljanja i/ili anotacije podataka direktno preuzeta odatle, maksimalan broj bodova za tu fazu/te faze projekta će biti umanjen, dok će maksimalan broj bodova za treću fazu biti uvećan.