

Detekcija klikbejt naslova u sportskim vestima na srpskom jeziku

Filip Nikolić (25/3234)

Danilo Nikolić (25/3235)

Obrada prirodnih jezika 2025/2026 — Elektrotehnički fakultet

Sažetak

Rad se bavi binarnom klasifikacijom sportskih naslova na srpskom jeziku na *klikbejt* i *regularne*. Skup od 2200 naslova (1100/1100) prikupljen je sa jednog izvora (portal Sport-Klub) i nezavisno anotiran od dva člana tima, uz međuanotatorsku saglasnost Cohen's $\kappa = 0,640$. Upoređena su tri tipa pristupa: osnovni modeli (logistička regresija i naivni Bajes nad TF/IDF/TF-IDF obeležjima), enkoderski jezički modeli (monolingvalni BERTić i višjejezični mBERT, fino podešeni) i dekoderski jezički model (Claude, bez fino podešavanja, zero-shot). Svi modeli su nadmašili osnovnu liniju; najbolju ukupnu tačnost i kalibrisane verovatnoće dao je BERTić (tačnost 0,704, ROC-AUC 0,788), dok je dekoderski model bez ijednog primera za obuku postigao najviši F1 na klikbejt klasi (0,715). Rezultati pokazuju da kontekstualni modeli znatno bolje hvataju suptilni klikbejt od pristupa zasnovanih na vreći reči.

Sadržaj

1	Uvod	2
1.1	Definicija klikbejta	2
2	Faza 1 — Prikupljanje podataka	2
3	Faza 2 — Anotacija podataka	3
3.1	Šema oznaka	3
3.2	Uputstvo za anotaciju	3
3.3	Kalibracija i međuanotatorska saglasnost (IAA)	3
3.4	Glavna anotacija	3
4	Deskriptivna statistika skupa	4
4.1	Raspodela klasa i dužina naslova	4
5	Faza 3 — Obučavanje i evaluacija modela	4
5.1	Protokol evaluacije	4
5.2	Osnovni modeli (LR + Naivni Bajes)	4
5.3	Enkoderski LLM (BERTić + mBERT)	5
5.4	Dekoderski LLM (Claude)	6
5.5	Uporedni pregled svih modela	7
6	Zaključak	7

1 Uvod

Klikbejt (engl. *clickbait*) je naslov koji je oblikovan tako da navede čitaoca na klik manipulacijom, a ne poštenim saopštavanjem vesti [7, 2]. U sportskom novinarstvu je posebno čest jer se rutinski događaji (transferi, izjave, rezultati) lako pakuju kao senzacija. Cilj ovog projekta je **binarna klasifikacija** sportskih naslova na klikbejt (oznaka 1) i regularne (oznaka 0), uz uporednu analizu tri porodice modela: klasičnih linearnih klasifikatora, fino podešenih enkoderskih transformera i dekoderskog (generativnog) jezičkog modela u režimu bez obuke. Rad prati četiri faze: prikupljanje podataka, anotaciju, obučavanje i evaluaciju modela, te dokumentaciju. U nastavku se opisuje svaka faza, daje deskriptivna statistika skupa i uporedna analiza rezultata.¹

1.1 Definicija klikbejta

Naslov ocenjujemo *sam za sebe*, onako kako ga čitalac vidi u listi vesti, bez otvaranja članka. Vodeće pitanje je: da li naslov *namerno* manipuliše čitaocem da klikne — uskraćivanjem informacije, preuveličavanjem ili veštačkom emocijom — umesto da pošteno saopšti vest. Razlikujemo četiri mehanizma manipulacije:

- **(KJ) Kognitivni jaz** — namerno izostavljanje ključne informacije (ko/šta/koliko/ishod), npr. „Real ozvaničio veliko pojačanje” (ne kaže koga).
- **(PV) Preuveličavanje važnosti** — rutinski događaj predstavljen kao senzacija, npr. „Bomba iz Italije” za običan transfer.
- **(EN) Veštački emocionalni naboj** — napetost ili ogorčenje koje ne proizilazi iz vesti, npr. „Skandal u Parizu”.
- **(SF) Senzacionalistička fraza / otvorena forma** — nedovršene rečenice s tri tačke, retorička pitanja, „nećete verovati”.

Za oznaku 1 dovoljan je jedan mehanizam. Naprotiv, uzvičnik, velika slova ili stvarno velika vest rečena direktno („Real ozvaničio Mbapea”) *ne* čine naslov klikbejtom. Ključni test: ako posle čitanja naslova znaš šta se desilo, naslov je verovatno regularan.

2 Faza 1 — Prikupljanje podataka

Izvor. Podaci su prikupljeni sa portala **SportKlub** preko njegovog WordPress REST API-ja (arhiva od oko 449 000 članaka). U prijavi su pomenuta tri izvora (Mozzart Sport, SportKlub, B92), ali smo se opredelili za *jedan* izvor. Postavka zahteva jedan tematski domen (sportske vesti), a ne određeni broj izvora; time što obe klase (klikbejt i regularan) dolaze sa istog portala, model uči stvarni klikbejt signal, a ne stil portala. Ovo je svesno odstupanje od prijave i ovde se eksplicitno obrazlaže.

Tehnika i metapodaci. Naslovi su povučeni programski preko REST API-ja (uz `requests` i ograničavanje učestalosti zahteva). Za svaki naslov beleže se metapodaci: jedinstveni `id`, tekst naslova (UTF-8), izvor, puni `url` članka, datum objave, rubrika i datum prikupljanja. Time je ispunjen zahtev da se zabeleži URL/jedinstveni identifikator izvora.

Čišćenje i deduplikacija. Sirovo je prikupljen višak (3000–4000 naslova) da bi se posle anotacije mogao izbalansirati skup. Sprovedena je egzaktna deduplikacija (identičan tekst) i približna deduplikacija (engl. *near-duplicate*, uz `rapidfuzz`) radi uklanjanja gotovo istih naslova. Finalni skup za Fazu 3 je balansiran na **2200 naslova (1100 klikbejt / 1100 regularan)**, sačuvan u UTF-8 tekstualnom formatu `dataset.tsv` (kolone `naslov` → `labela`). Format TSV je standardni UTF-8 tekstualni format za klasifikaciju teksta i odgovara zahtevu za „UTF-8 TXT”.

¹Projekat radi dvočlana grupa, uz izričito odobrenje predavača za rad u paru.

3 Faza 2 — Anotacija podataka

3.1 Šema oznaka

Svakom naslovu dodeljuje se jedna binarna oznaka: 1 (klikbejt) ili 0 (regularan). Mehanizmi manipulacije (KJ/PV/EN/SF) korišćeni su kao pomoć pri odlučivanju; pod-tipovi su opcioni i nisu sistematski unošeni u finalni skup.

3.2 Uputstvo za anotaciju

Uputstvo (`annotation/guidelines.md`) definiše svaki mehanizam, navodi šta *nije* klikbejt (uzvičnik, velika slova, velika vest rečena direktno, informativni citati, rezultati i izveštaji sa jasnim sadržajem) i daje rešene granične primere. Naslov se uvek ocenjuje izolovano, bez otvaranja članka.

3.3 Kalibracija i međuanotatorska saglasnost (IAA)

Pre glavne anotacije, oba anotatora su *nezavisno* označila kalibracioni skup od 220 naslova radi merenja saglasnosti. Kao mera korišćen je Cohen's κ (prikladan za dva anotatora; sa dva člana postoji jedan par, pa je grupni prosek jednak tom paru). Rezultati su u Tabeli 1.

Tabela 1: Međuanotatorska saglasnost na kalibracionom skupu.

Mera	Vrednost
Kalibracionih parova	220 / 220
Procentualno slaganje (P_o)	82,7 % (182/220)
Cohen's kappa	0,640
Neslaganja	38 / 220 (17,3 %)


Postignuti $\kappa = 0,640$ prelazi internu ciljanu granicu $\kappa \geq 0,6$ i spada u opseg „dobre” saglasnosti. Analiza neslaganja pokazuje *dosledan, jednosmeran* pomeraj praga: u 25 od 38 neslaganja (66 %) jedan anotator je naslov video kao klikbejt, a drugi kao regularan, i to u istom smeru — blaži senzacionalizam i emotivni epiteti („za istoriju”, „šokantno”) shvataju se različito strogo. Ovakav semantički (a ne površinski) pomeraj tipičan je za suptilne granične slučajeve i ne obara κ ispod praga. Na osnovu ovih slučajeva uvedeno je operativno pravilo: emotivni epiteti sami po sebi nisu dovoljni za oznaku 1 — moraju biti praćeni preuveličavanjem ili uskraćivanjem informacije.

3.4 Glavna anotacija

Posle kalibracije, preostali naslovi su podeljeni na pola i anotirani jednostruko. Preklapajući (sporni) naslovi iz kalibracije rešeni su *adjudikacijom* — usaglašena labela ušla je u finalni skup. Vrednost $\kappa = 0,640$ prijavljuje se kao mera *nezavisne* saglasnosti, pre adjudikacije.

4 Deskriptivna statistika skupa

4.1 Raspodela klasa i dužina naslova



Slika 1: Levo: raspodela klasa. Desno: dužina naslova (reči) po klasi.

Finalni skup za obuku je namerno balansiran (1100/1100), čime se uklanja pristrasnost klasifikatora prema većinskoj klasi i pojednostavljuje tumačenje metrika. Dužina naslova slabo razdvaja klase: klikbejt naslovi su u proseku tek neznatno duži (prosečno 9,0 reči / 55,2 karaktera) od regularnih (8,4 reči / 53,3 karaktera). Praktično preklapanje raspodela dužina znači da puka dužina nije koristan signal — razlika je u *značenju i formi*, a ne u broju reči, što je u skladu sa slabim rezultatima modela zasnovanih na vreći reči (Odeljak 5.2). Po rubrikama su obe klase ravnomerno zastupljene (fudbal, Evroliga, Rolan Garos, Superliga, ABA liga...), pa rubrika nije izvor pristrasnosti.

5 Faza 3 — Obučavanje i evaluacija modela

5.1 Protokol evaluacije

Osnovni i enkoderski modeli ocenjeni su **10-strukom stratifikovanom unakrsnom validacijom**; za osnovne modele hiperparametri su birani *ugnežđenom* unakrsnom validacijom (engl. *nested CV*) da bi se izbeglo curenje informacija. Da bi ocena bila poštena, pretprocesiranje (stemovanje/lematizacija) radi se nad celim skupom, ali se vektorizator (vokabular i IDF težine) uči *unutar svakog fold-a*. Dekoderski model ocenjen je nad celim skupom (2200). Za sve modele izveštavaju se iste metrike: tačnost, preciznost/odziv/F1 sa fokusom na klikbejt klasu, makro-F1 i ROC-AUC (gde model daje verovatnoće).

5.2 Osnovni modeli (LR + Naivni Bajes)

Ispitan je grid varijanti: pretprocesiranje (bez / heuristički stemer / lematizacija), ponderisanje obeležja (TF / IDF / TF-IDF / puko brojanje) i opseg n-grama (1–1, 1–2). Implementacija se oslanja na `scikit-learn` [6], a lematizacija na `classla` [4]. Po preporuci profesora ne izbacuju se stop-reči; umesto toga oslanjamo se na TF/IDF/TF-IDF ponderisanje.

Tabela 2: Osnovni modeli — efekat preprocessinga i odlika.

Model	Norm.	Šema	n-gram	F1 _{kb}	Acc.	AUC
mnb	stem	tfidf	1-2	0.646±0.045	0.622±0.050	0.676±0.059
mnb	stem	bow	1-2	0.642±0.048	0.625±0.050	0.678±0.060
mnb	stem	tf	1-2	0.642±0.045	0.622±0.047	0.677±0.059
mnb	stem	tf	1-1	0.641±0.050	0.624±0.051	0.682±0.060
mnb	lemma	tf	1-2	0.641±0.038	0.632±0.038	0.686±0.051
mnb	lemma	bow	1-2	0.638±0.034	0.631±0.032	0.681±0.052
mnb	lemma	tf	1-1	0.637±0.046	0.631±0.044	0.684±0.056
mnb	lemma	tfidf	1-2	0.636±0.034	0.627±0.033	0.679±0.048
mnb	lemma	bow	1-1	0.634±0.038	0.630±0.033	0.681±0.056
mnb	stem	tfidf	1-1	0.634±0.056	0.613±0.055	0.675±0.063
mnb	stem	bow	1-1	0.632±0.052	0.619±0.052	0.678±0.062
logreg	lemma	tf	1-1	0.632±0.054	0.637±0.049	0.677±0.057
mnb	lemma	tfidf	1-1	0.631±0.044	0.620±0.043	0.677±0.052
logreg	lemma	idf	1-1	0.630±0.041	0.629±0.037	0.675±0.052
logreg	lemma	tf	1-2	0.629±0.050	0.631±0.047	0.679±0.054
logreg	lemma	tfidf	1-1	0.627±0.060	0.635±0.050	0.677±0.057
logreg	lemma	idf	1-2	0.626±0.042	0.627±0.037	0.676±0.050
logreg	lemma	tfidf	1-2	0.625±0.041	0.630±0.038	0.682±0.053
mnb	none	tf	1-1	0.624±0.045	0.610±0.044	0.662±0.056
mnb	none	tfidf	1-1	0.623±0.036	0.602±0.037	0.654±0.053

Prikazano top 20 (po F1 klikbejt klase), nested 10-fold CV.

Najbolja varijanta je **multinomijalni naivni Bajes uz stemovanje i TF-IDF (1–2 grami)**, sa F1 na klikbejt klasi 0,646 i ROC-AUC 0,676. Razlike među shemama ponderisanja su male: na kratkim naslovima IDF komponenta donosi ograničenu korist jer se reči retko ponavljaju, pa puko brojanje nije daleko od TF-IDF. Stemovanje pomaže (smanjuje raštrkanost zbog morfologije srpskog), dok bigrami donose tek neznatno poboljšanje. Glavni zaključak: pristup zasnovan na vreći reči hvata površinske leksičke obrasce, ali teško prepoznaje suptilni klikbejt koji zavisi od konteksta i implikacije.

5.3 Enkoderski LLM (BERTić + mBERT)

Fino su podešena dva enkoderska modela — monolingvalni **BERTić** (za BCMS jezike) [5] i višjezični **mBERT** [3] — uz variranje broja epoha (2/3/4) i 10-struku validaciju.


Tabela 3: Enkoderski LLM — BERTić vs mBERT, varijante epoha.

Model	Epohe	F1 _{kb}	Acc.	P _{kb}	R _{kb}	AUC
bertic	2	0.681±0.042	0.680±0.034	0.678±0.036	0.688±0.069	0.760±0.036
bertic	3	0.703±0.034	0.704±0.035	0.707±0.047	0.703±0.050	0.785±0.036
bertic	4	0.703±0.034	0.702±0.035	0.703±0.039	0.704±0.038	0.788±0.030
mbert	2	0.651±0.042	0.664±0.034	0.678±0.040	0.629±0.063	0.736±0.042
mbert	3	0.690±0.042	0.687±0.041	0.685±0.045	0.699±0.058	0.753±0.042
mbert	4	0.682±0.041	0.691±0.036	0.703±0.042	0.664±0.054	0.755±0.038

10-slojna stratifikovana CV.

Mono > multi: BERTić nadmašuje mBERT na svim metrikama, što potvrđuje da model treniran specifično za srpski (i srodne jezike) bolje hvata jezičke nijanse. **Broj epoha:** 2 epohe

su nedovoljne, dok 3–4 epohe daju najbolji i stabilan rezultat (F1 0,703, tačnost 0,704, ROC-AUC do 0,788); dalje obučavanje ne donosi dobitak (vidi krivu učenja na Slici 2). U poređenju sa osnovnom linijom, čak i slabiji transformer (mBERT, F1 0,690) je +0,044 iznad najboljeg osnovnog modela, a razlika po ROC-AUC-u je još veća (+0,11) — kontekstualni modeli znatno bolje razdvajaju klase.



Slika 2: Kriva učenja (F1/AUC u funkciji broja epohe) za enkoderske modele.

5.4 Dekoderski LLM (Claude)

Dekoderski (generativni) model **Claude (Haiku)** [1] primenjen je *bez fino podešavanja*, u režimu zero-shot, nad celim skupom.² Upoređene su dve prompt varijante — na srpskom (SR) i engleskom (EN) jeziku — obe sa definicijom klikbejta. Odgovori se kešuju radi prekida/nastavka i da se ne plaća dvostruko.

Tabela 4: Dekoderski LLM (Claude) — SR vs EN, zero/few-shot.

Varijanta	Jezik	Shots	F1 _{kb}	Acc.	P _{kb}	R _{kb}
en_zero_def	en	zero	0.715	0.691	0.664	0.775
sr_zero_def	sr	zero	0.710	0.695	0.676	0.748

Evaluacija na celom skupu.


Jezik upita (SR vs EN): razlika je zanemarljiva (F1 0,710 naspram 0,715), uz neznatnu prednost engleskog prompta. **Snaga bez obuke:** model bez ijednog primera za obuku postiže *najviši F1 na klikbejt klasi* u celom radu (0,715), blago iznad fino podešenog BERTića (0,703). Ograničenja su, međutim, suštinska: model vraća *tvrd* odluku 0/1, pa nema verovatnoća ni ROC-AUC-a; zavisi od plaćenog API-ja i dnevnih ograničenja poziva; i nije lokalna. Evaluirane su dve prompt varijante (SR/EN, zero-shot, sa definicijom); few-shot i kalibracija ostaju za dalji rad.

²U prijavi je naveden ChatGPT; postavka projekta izričito dozvoljava i druge dekodrske modele, pa je korišćen Claude (Haiku) kao funkcionalno ekvivalentan zatvoreni generativni model dostupan preko API-ja.

5.5 Uporedni pregled svih modela

Tabela 5: Uporedni pregled — najbolja varijanta po tipu modela.

Najbolji po tipu	$F1_{kb}$	Acc.	AUC
Baseline (mnb, tfidf)	0.646 ± 0.045	0.622 ± 0.050	0.676 ± 0.059
Enkoderski (bertic)	0.703 ± 0.034	0.704 ± 0.035	0.785 ± 0.036
Enkoderski (mbert)	0.690 ± 0.042	0.687 ± 0.041	0.753 ± 0.042
Claude (en_zero_def)	0.715	0.691	—



Slika 3: F1 (klikbejt klasa) najboljih varijanti po tipu modela.

Svi modeli nadmašuju osnovnu liniju. Po $F1$ na *klikbejt klasi* vodi dekoderski Claude (0,715), ali po *tačnosti* i kalibrisanim verovatnoćama (ROC-AUC) najbolji je BERTić (0,704 / 0,788). Drugim rečima, ne postoji jedinstveni pobednik: dekodera je najbolji kada nema podataka za obuku, a enkoder kada su potrebne pouzdane verovatnoće i lokalno, besplatno izvršavanje.

6 Zaključak

Pokazali smo da je detekcija klikbejt sportskih naslova na srpskom izvodljiva i da izbor modela zavisi od ograničenja primene. **Za produkciju** preporučujemo **BERTić**: mali, besplatan, lokalni, daje kalibrisane verovatnoće (ROC-AUC 0,788) i najbolju tačnost, uz najbolji odnos cena/kvalitet. **Kada nema podataka za obuku**, dekoderski model (Claude, zero-shot) je konkurentan i postiže najviši F1 bez ijednog označenog primera, po cenu plaćenog API-ja i odsustva verovatnoća. Osnovni modeli ostaju korisni kao brza, transparentna referenca.

Ograničenja. Skup je relativno mali (2200), iz jednog domena (sport) i sa jednog izvora (SportKlub); dekodera daje samo tvrde labele (bez AUC-a); evaluirane su dve prompt varijante. **Dalji rad.** Više domena i izvora, veći skup, few-shot prompting i kalibracija dekodera, ansambl (BERTić + dekodera) i analiza tipova grešaka po pod-tipovima klikbejta (KJ/PV/EN/SF).

Literatura

- [1] Anthropic. The Claude 3 model family: Opus, Sonnet, Haiku. *Anthropic Technical Report*, 2024.
- [2] Abhijnan Chakraborty, Bhargavi Paranjape, Sourya Kakarla, and Niloy Ganguly. Stop clickbait: Detecting and preventing clickbaits in online news media. In *Proceedings of the IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM)*, 2016.
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, 2019.
- [4] Nikola Ljubešić and Kaja Dobrovoljc. CLASSLA-StanfordNLP: A tool for the processing of croatian, serbian and slovenian. In *Proceedings of the 7th Workshop on Balto-Slavic Natural Language Processing (BSNLP)*, 2019.
- [5] Nikola Ljubešić and Davor Lauc. BERTić – the transformer language model for bosnian, croatian, montenegrin and serbian. In *Proceedings of the 8th Workshop on Balto-Slavic Natural Language Processing (BSNLP)*, 2021.
- [6] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [7] Martin Potthast, Sebastian Köpsel, Benno Stein, and Matthias Hagen. Clickbait detection. *Advances in Information Retrieval (ECIR)*, 2016.